



CLASSIFICAÇÃO DA QUALIDADE DE VINHOS

Como o Machine Learning pode prever a qualidade de um vinho antes mesmo da avaliação sensorial



**Hoje, a qualidade
de um vinho é
definida por
degustação humana**

O DESAFIO DE NEGÓCIO

Uma avaliação valiosa, mas lenta e subjetiva

- Depende de especialistas, aroma, sabor e experiência pessoal — o resultado pode variar de avaliador para avaliador.
- É um processo demorado, aplicado normalmente apenas no fim da produção.
- Dificulta ajustes rápidos ao longo do processo produtivo.

A pergunta que este projeto responde:

É possível prever a qualidade do vinho usando apenas dados de laboratório, de forma objetiva e rápida?

NOSSO OBJETIVO

Treinar um modelo para reconhecer um vinho de alta qualidade



VINHO DE ALTA QUALIDADE

Nota ≥ 7

Vinhos que se destacam na avaliação sensorial dos especialistas.



VINHO DE BAIXA/MÉDIA QUALIDADE

Nota < 7

A grande maioria da produção, com qualidade padrão ou regular.

A BASE DE CONHECIMENTO

Quase 1.150 vinhos analisados em laboratório

1.143

Amostras de
vinho tinto

11

Medidas físico-
químicas por amostra

2

Categorias finais:
alta e baixa/média qualidade

Exemplos de variáveis medidas em laboratório:

Teor Alcoólico

Acidez

Açúcar Residual

Densidade

Sulfatos

pH

Dióxido de Enxofre


O QUE ENCONTRAMOS NOS DADOS

Vinhos de alta qualidade são raros

Esse desequilíbrio é um risco real: sem o cuidado certo, um modelo pode parecer preciso no papel e, ainda assim, falhar justamente em apontar os vinhos que mais interessam ao negócio.



Apenas 14 em cada 100 vinhos analisados atingem nota de alta qualidade.



Dois fatores se destacam antes mesmo do modelo



TEOR ALCOÓLICO

Quanto maior, melhor

Vinhos com mais álcool tendem a ter mais corpo e complexidade — e isso se reflete diretamente numa nota mais alta.

Relação mais forte encontrada entre todas as variáveis analisadas.



ACIDEZ VOLÁTIL

Quanto menor, melhor

Níveis altos indicam gosto e cheiro de vinagre — um defeito claro que reduz fortemente a avaliação do vinho.

Segundo fator de maior impacto, e o principal sinal de alerta de qualidade.

NOSSA ABORDAGEM

Testamos três modelos de Machine Learning para chegar ao mais confiável




Regressão Logística

Abordagem simples e transparente, usada como ponto de partida



Random Forest

Combina centenas de "árvores de decisão" para um resultado mais robusto



Gradient Boosting

Aprende com os próprios erros, refinando a previsão passo a passo



Por que três modelos? Cada abordagem "enxerga" os dados de um jeito diferente — testar várias aumenta a chance de encontrar o melhor previsor possível.

COMO AVALIAMOS

Uma comparação justa, com três perguntas simples

Todos os modelos foram testados com os mesmos vinhos — amostras que eles nunca tinham visto antes, garantindo uma comparação honesta.



Acerto Geral

De todos os vinhos testados, quantos o modelo classificou corretamente?



Confiabilidade da Indicação

Quando o modelo aponta um vinho como "alta qualidade", ele está certo com que frequência?




Capacidade de Encontrar os Bons Vinhos

De todos os vinhos realmente bons, quantos o modelo conseguiu identificar?

RESULTADOS

O Random Forest foi o mais equilibrado — mas cada modelo tem um ponto forte



RESULTADOS NA PRÁTICA

O que o modelo vencedor entrega, na prática

Considerando o desempenho do Random Forest, a cada 100 vinhos avaliados pelo modelo:

91

vinhos são
classificados corretamente
(acerto geral)

72

em cada 100 indicações de
"alta qualidade" estão certas
(confiabilidade)


56

dos vinhos realmente bons
são identificados pelo modelo
(cobertura)

O QUE O MODELO APRENDEU

O modelo confirma o que a análise já indicava

Fatores que mais pesaram na decisão da Floresta de Decisão ao classificar um vinho:



O que isso significa na prática para a produção



Monitoramento antecipado

Acompanhar teor alcoólico e acidez volátil durante a produção, antes da avaliação final, permite prever problemas com antecedência.



Ajustes no processo

Lotes com sinais de baixa qualidade podem ser corrigidos ainda durante a vinificação, reduzindo perdas.



Decisão mais rápida

O modelo apoia — não substitui — o enólogo, agilizando decisões que hoje dependem só da degustação final.



Da degustação subjetiva à decisão orientada por dados

Um modelo com mais de 90% de acerto, pronto para apoiar decisões de produção
com agilidade e consistência.

Obrigado!